Analyse immobilière DVF : modélisation et requêtes SQL avancées

Laplace Immo

D'AURA Rémy

CONTEXTE DU PROJET 🎯

Contexte : Le Projet DATAImmo

- **Objectif :** Créer un modèle prédictif de prix pour l'agence Laplace Immo
- **Mission :** Structurer et analyser les données transactionnelles pour éclairer les agences régionales.
- **Sources :** Consolidation de **DVF** (Transactions), **INSEE** (Population) et **Data.gouv** (Géographie).
- **Conformité :** Base **conforme au RGPD** (données anonymisées et publiques).

PROBLÉMATIQUE & AXES D'ANALYSE

Problématique : Comment utiliser le SQL avancé pour transformer les données brutes DVF en indicateurs stratégiques de Valorisation et de Dynamisme du marché ?

Axe Stratégique	Objectif
Valorisation Géographique	Identifier les communes *premium* (Top 3 par département).
Pression Démographique	Mesurer le **renouvellement immobilier** (Transactions / 1 000 habitants).
Segmentation & Chocs	Analyser les **primes au logement** (2P vs 3P) et l'impact temporel (T1 2020).



LE DICTIONNAIRE DES DONNÉES ENRICHI

Objectif

But : Documenter l'ensemble des variables pour garantir la cohérence des types et l'intégrité des données.

Principe

Atomicité : Chaque variable est indivisible (ex: la date est stockée dans un format unique `AAAA-MM-JJ`).

Conformité RGPD : Le dictionnaire confirme l'absence de colonnes à caractère personnel (nom, prénom, adresse précise).

EXTRAIT DES VARIABLES CLÉS (DICTIONNAIRE)

VENTE

Date mutation	Date de la mutation (vente)	DATE	10 E	Format JJ/MM/AAAA
Valeur fonciere	Valeur du bien en euros	FLOAT	12 E	Montant total de la mutation

BIEN

Surface terrain	Surface du terrain en m²	INTEGER		8 E
code dep code com	Concaténation	VARCHAR	6 E	Clé de jointure vers la commune

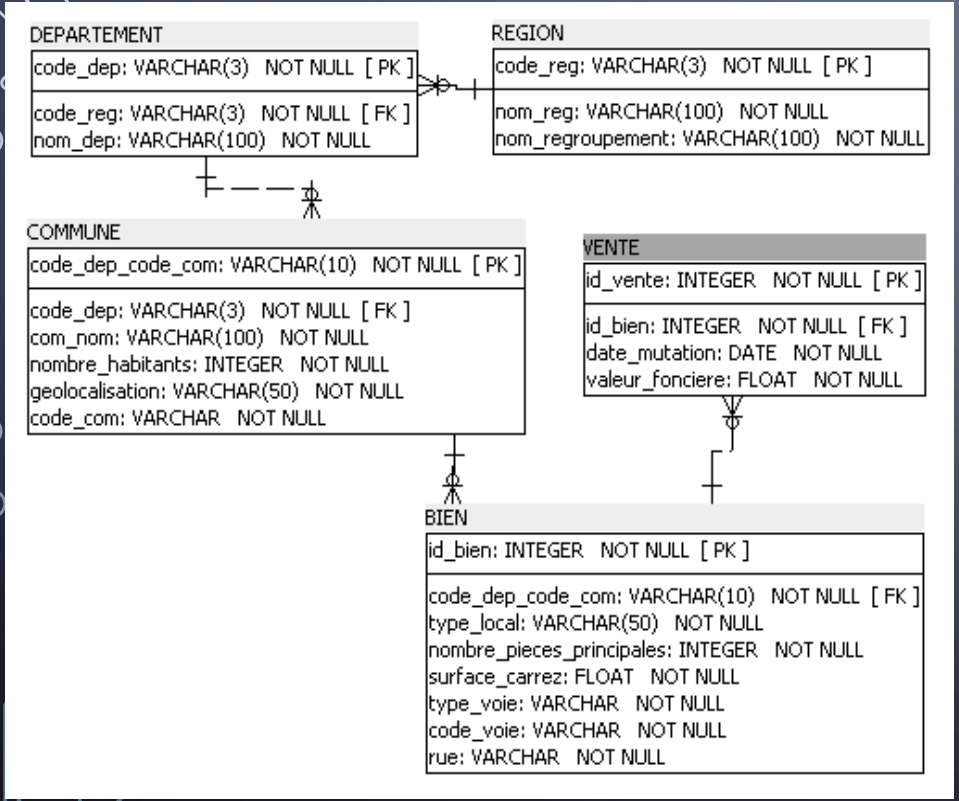
COMMUNE

com nom	Nom complet de la commune	VARCHAR		50 E
PTOT	Population totale	INTEGER	8 E	PMUN + PCAP

DEPARTEMENT

dep code	Code du département	VARCHAR	3 E	Clé primaire dep

SCHÉMA RELATIONNEL NORMALISÉ (3NF)



Justification de la Conception

- Respect de la 3e Forme Normale (3NF)
- Intégration Géographique
- Intégrité et Cohérence

CONFORMITÉ, SAUVEGARDE ET CONTINUITÉ

1. Conformité Réglementaire (RGPD)

-Conclusion : La base de données est Conforme.
-Justification : Utilisation exclusive de données publiques et anonymisées (DVF, INSEE).
-Exclusion : Aucune donnée à caractère personnel n'est stockée.

2. Stratégie d'Intégrité et d'Optimisation

Aspect	Choix pour DATAImmo	Justification
Type	**Sauvegarde Complète (Full Backup)**	Stockage de la totalité de la base pour une restauration rapide en cas de désastre.
Fréquence	**Quotidienne (Hors heures d'ouverture)**	Assure que nous ne perdons jamais plus de 24h de travail, essentiel pendant la phase de modélisation intensive.
Localisation	**Distant (Cloud Sécurisé)**	Évite la perte totale des données en cas de défaillance matérielle locale.

LA BASE DE DONNÉES IMPLÉMENTÉE

1. Implémentation Physique des Tables

-SGBD Utilisé : MySQL

-Vérification de la Structure : Les 5 tables du Schéma Relationnel sont créées et reliées.

Table	Action						Lignes	Type
bien	Parcourir	Structure	Rechercher	Insérer	Vider	Supprimer	34 169	InnoDB
commune	Parcourir	Structure	Rechercher	Insérer	Vider	Supprimer	34 991	InnoDB
departement	Parcourir	Structure	Rechercher	Insérer	Vider	Supprimer	109	InnoDB
region	Parcourir	Structure	Rechercher	Insérer	Vider	Supprimer	19	InnoDB
vente	Parcourir	Structure	Rechercher	Insérer	Vider	Supprimer	34 169	InnoDB

2. Intégrité des Types de Variables

Le respect des types de variables logiques est assuré

ASSURANCE QUALITÉ & OPTIMISATION DE LA BASE

1. Assurance Qualité des Données

Point d'Intégrité	Justification	Impact Métier
Clés Étrangères (FK)	Actives sur les 5 tables (VENTE ->BIEN ->COMMUNE...).	**Cohérence :** Garantit qu'un bien ne peut exister sans une commune valide, assurant l'exactitude des analyses régionales.
Conversion de Type	date_mutation (texte) convertie au type **DATE**.	**Fiabilité :** Permet des filtres et des calculs temporels exacts (comparaison trimestrielle, annuelle) optimisés par MySQL.
Atomicité	Validée par le Dictionnaire : chaque colonne est une information unique et indivisible.	**Précision :** Évite les ambiguïtés dans les calculs (ex: prix au m^2).

2. Optimisation pour la Performance

Technique d'Optimisation	Requête SQL Associée	Bénéfice pour DATAImmo
Création d'Index	CREATE INDEX idx_bien_code_com ON BIEN (code_dep_code_com);	**Performance :** Accélère massivement les jointures géographiques, essentielles pour toutes nos requêtes d'analyse Top N.

Analyse 1 : Valorisation géographique 📍

```sql
SELECT
    T_Classe.Nom_Departement,
    T_Classe.Nom_Commune,
    T_Classe.Valeur_Fonciere_Moyenne
FROM
    (
        SELECT
            C.com_nom AS Nom_Commune,
            D.nom_dep AS Nom_Departement,
            ROUND(AVG(V.valeur_fonciere), 0) AS Valeur_Fonciere_Moyenne,
            RANK() OVER (
                PARTITION BY D.code_dep
                ORDER BY AVG(V.valeur_fonciere) DESC
            ) Rang_Departement_Col
        FROM
            VENTE V
        INNER JOIN
            BIEN B ON V.id_bien = B.id_bien
        INNER JOIN
            COMMUNE C ON B.code_dep_code_com = C.code_dep_code_com
        INNER JOIN
            DEPARTEMENT D ON C.code_dep = D.code_dep
        WHERE
            D.code_dep IN ('06', '13', '33', '59', '69')
            AND V.valeur_fonciere IS NOT NULL
            AND V.valeur_fonciere > 0
        GROUP BY
            C.com_nom, D.nom_dep, D.code_dep
    ) AS T_Classe
WHERE
    T_Classe.Rang_Departement_Col <= 3
ORDER BY
    T_Classe.Nom_Departement,
    T_Classe.Rang_Departement_Col;
```

Les moyennes de valeurs foncières pour le top 3 des communes des départements 6, 13, 33, 59 et 69

Nom_Departement ▲ 1	Nom_Commune	Valeur_Fonciere_Moyenne
Alpes-Maritimes	Saint-Jean-Cap-Ferrat	968750
Alpes-Maritimes	Eze	655000
Alpes-Maritimes	Mouans-Sartoux	476898
Bouches-du-Rh?ne	Gignac-la-Nerthe	330000
Bouches-du-Rh?ne	Saint-Savournin	314425
Bouches-du-Rh?ne	Cassis	313417
Gironde	L?ge-Cap-Ferret	549501
Gironde	Vayres	335000
Gironde	Arcachon	307436
Nord	Bers?e	433202
Nord	Cysoing	408550
Nord	Halluin	322250
Rh?ne	Ville-sur-Jarnioux	485300
Rh?ne	Lyon 2e Arrondissement	455217
Rh?ne	Lyon 6e Arrondissement	426968

ANALYSE 2 : PRESSION DÉMOGRAPHIQUE

```sql
SELECT
    C.com_nom AS Nom_Commune,
    C.code_dep_code_com AS Code_INSEE,
    COUNT(V.id_vente) AS Nombre_Total_Ventes,
    C.nombre_habitants AS Population_Totale,
    -- Calcul du ratio : (Nombre de Ventes / Population) * 1000
    ROUND(
        (CAST(COUNT(V.id_vente) AS REAL) * 1000) / C.nombre_habitants,
        2
    ) AS Transactions_pour_1000_Habitants
FROM
    VENTE V
INNER JOIN
    BIEN B ON V.id_bien = B.id_bien
INNER JOIN
    COMMUNE C ON B.code_dep_code_com = C.code_dep_code_com
WHERE
    -- 1. Filtre démographique : Communes de plus de 10 000 habitants
    C.nombre_habitants > 10000
    AND C.nombre_habitants IS NOT NULL
GROUP BY
    C.com_nom,
    C.code_dep_code_com,
    C.nombre_habitants -- La population doit être incluse dans le GROUP BY
HAVING
    -- 2. Filtre de volume : S'assurer que la commune a eu au moins une transaction
    COUNT(V.id_vente) > 0
ORDER BY
    Transactions_pour_1000_Habitants DESC -- Classement par le ratio le plus élevé
LIMIT 20; -- Limiter au Top 20
```

Les 20 communes avec le plus de transactions pour 1000 habitants pour les communes qui dépassent les 10 000 habitants.

Calcul Clé : Ratio de densité transactionnelle : Nombre total de ventes / Population totale * 1000

Nom_Commune	Code_INSEE	Nombre_Total_Ventes	Population_Totale	Transactions_pour_1000_Habitants
Paris 2e Arrondissement	75102	127	21595	5.88
Paris 1er Arrondissement	75101	79	15917	4.96
La Baule-Escoublac	44055	77	16255	4.74
Arcachon	33009	55	11630	4.73
Paris 3e Arrondissement	75103	161	34025	4.73
Paris 4e Arrondissement	75104	120	29131	4.12
Roquebrune-Cap-Martin	06104	52	12839	4.05
Paris 8e Arrondissement	75108	139	35655	3.9
Sanary-sur-Mer	83123	60	16889	3.55
La Londe-les-Maures	83071	37	10641	3.48
Paris 9e Arrondissement	75109	208	60026	3.47
Paris 6e Arrondissement	75106	139	40303	3.45
Saint-Cyr-sur-Mer	83112	38	11484	3.31
Chantilly	60141	35	10950	3.2
Pornichet	44132	35	11141	3.14
Saint-Mand?	94067	69	22377	3.08
Paris 10e Arrondissement	75110	264	86472	3.05
Menton	06083	91	30525	2.98
Saint-Hilaire-de-Riez	85226	33	11297	2.92
Vincennes	94080	141	49788	2.83

ANALYSE 3 : SEGMENTATION ET ÉVOLUTION DU MARCHÉ 📈

```sql
SELECT
    -- Calcul de la moyenne du prix/m² pour les appartements de 2 pièces
    ROUND(AVG(CASE WHEN B.nombre_pieces_principales = 2 THEN V.valeur_fonciere / B.surface_reelle_bati ELSE NULL END), 2) AS Prix_m2_Moyen_2Pieces,

    -- Calcul de la moyenne du prix/m² pour les appartements de 3 pièces
    ROUND(AVG(CASE WHEN B.nombre_pieces_principales = 3 THEN V.valeur_fonciere / B.surface_reelle_bati ELSE NULL END), 2) AS Prix_m2_Moyen_3Pieces,

    -- Calcul de la différence en pourcentage : ((Prix m² 3P - Prix m² 2P) / Prix m² 2P) * 100
    ROUND(
        (
            (
                AVG(CASE WHEN B.nombre_pieces_principales = 3 THEN V.valeur_fonciere / B.surface_reelle_bati ELSE NULL END)
                -
                AVG(CASE WHEN B.nombre_pieces_principales = 2 THEN V.valeur_fonciere / B.surface_reelle_bati ELSE NULL END)
            )
            /
            AVG(CASE WHEN B.nombre_pieces_principales = 2 THEN V.valeur_fonciere / B.surface_reelle_bati ELSE NULL END)
        ) * 100
    , 2) AS Difference_Pourcentage
FROM
    VENTE V
INNER JOIN
    BIEN B ON V.id_bien = B.id_bien
WHERE
    B.nombre_pieces_principales IN (2, 3)
    AND B.type_local = 'Appartement'
    AND V.valeur_fonciere IS NOT NULL
    AND B.surface_reelle_bati > 0;
```

Prix_m2_Moyen_2Pieces	Prix_m2_Moyen_3Pieces	Difference_Pourcentage
4927.8	4285.37	-13.04

Différence en pourcentage du prix au mètre carré entre un appartement de 2 pièces et un appartement de 3 pièces.

Technique : Utilisation de l'**Agrégation Conditionnelle** (via SUM(CASE WHEN...)) et des **Fonctions de Date** (YEAR(), MONTH(), QUARTER()).

CONCLUSION ET PROCHAINES ÉTAPES DATAIMMO 🚀

1. Bilan du Projet : De la Conception à l'Analyse :

-Structure Validée : Schéma Relationnel **3NF** et Dictionnaire des Données sont validés et implémentés (Conformité RGPD assurée).

-Base Opérationnelle : Intégrité et fiabilité garanties par l'usage des FK, conversion des types (DATE), et **indexation** pour la performance.

-Analyse Stratégique : Les requêtes avancées (Fonctions de Fenêtre, Ratios, Agrégations Conditionnelles) ont permis de dégager des indicateurs clés :

- **Top 3 des Communes** (Valorisation).
- **Taux de Renouvellement** (Dynamisme par habitant).



CONCLUSION ET PROCHAINES ÉTAPES DATAIMMO 🚀

2. Prochaines Étapes Stratégiques

Objectif Suivant	Phase du Projet	Rôle
Nettoyage et Préparation	Finaliser le nettoyage des valeurs aberrantes (NULL, outliers de valeur_fonciere).	Assurer la qualité des données pour l'IA.
Création de la Couche Analytique	Développer des vues et des requêtes optimisées pour l'équipe Data Science.	Faciliter l'extraction des *features* (variables).
Modèle Prédictif	Démarrage de la modélisation du prix de vente.	**Objectif Final de DATAImmo.**